

Predicción de ventas con técnicas de machine learning aplicadas a series temporales de contrataciones

Mg. Juan Pablo Skobalski

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Juan Cruz Skobalski

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Buenos Aires, junio de 2026

Resumen

En este trabajo se desarrolló un modelo de aprendizaje automático, junto con un flujo de procesamiento de datos reproducible, para proyectar las contrataciones de una empresa a partir de fotografías semanales históricas de su sistema de gestión comercial. En el trabajo se aplicaron de manera integrada contenidos de la Especialización, entre ellos el análisis y la preparación de datos, el aprendizaje automático, las series temporales y la evaluación de modelos.

Índice general

Resumen	I
1. Introducción general	1
1.1. Desafíos del pronóstico de ventas B2B	1
1.2. Contexto y motivación	2
1.3. Descripción del problema	2
1.4. Estado del arte	3
1.4.1. Pronósticos estadísticos y basados en juicio experto	3
1.4.2. Aprendizaje automático aplicado al embudo comercial	3
1.4.3. Agregación temporal	4
1.5. Objetivos	4
1.6. Alcance del trabajo	5
2. Introducción específica	7
2.1. Conjunto de datos	7
2.1.1. Estructura y variables disponibles	8
2.1.2. Contrataciones históricas	8
2.1.3. Calidad, limitaciones y confidencialidad	9
2.2. Salida esperada e información predictiva	9
2.3. Modelos considerados	10
2.4. Métricas de evaluación	10
2.5. Entorno tecnológico	11
2.6. Infraestructura de cómputo	12
3. Diseño e implementación	13
3.1. Análisis del software	13
4. Ensayos y resultados	15
4.1. Pruebas funcionales del hardware	15
5. Conclusiones	17
5.1. Conclusiones generales	17
5.2. Próximos pasos	17
Bibliografía	19

Índice de figuras

Índice de tablas

2.1. Resumen del conjunto de datos utilizado en el trabajo.	7
2.2. Familias de modelos y bibliotecas utilizadas.	10
2.3. Herramientas principales del entorno tecnológico.	12

Capítulo 1

Introducción general

En este capítulo se introduce el problema de la proyección de contrataciones a partir de información comercial histórica. Se presenta el rol del pronóstico de ventas en la planificación de una organización y se describen los desafíos propios de las ventas entre empresas. Luego se expone el contexto que motivó el trabajo y se formula el problema técnico. Finalmente, se revisan los principales enfoques propuestos en la literatura y se establecen los objetivos y el alcance del trabajo.

1.1. Desafíos del pronóstico de ventas B2B

La proyección de ventas constituye un insumo central para la planificación financiera de una organización. A partir de ella se estiman ingresos, se asignan recursos, se definen metas y se anticipan necesidades de capacidad. En entornos empresariales, esta tarea suele combinar información histórica con el conocimiento de los responsables comerciales. Los sistemas de pronóstico brindan una base cuantitativa, mientras que las personas incorporan información contextual que no siempre se encuentra representada en los datos. Sin embargo, los ajustes basados en juicio experto no mejoran necesariamente la precisión y pueden introducir sesgos, en particular cuando son frecuentes, pequeños o excesivamente optimistas [1].

Los sistemas de gestión de relaciones con clientes o CRM (*Customer Relationship Management*) registran de manera estructurada la actividad comercial. Para cada oportunidad pueden almacenar su monto esperado, la probabilidad estimada de cierre, la etapa dentro del proceso de venta, la fecha prevista de concreción y otras características relevantes. Además de facilitar el seguimiento operativo, estos registros permiten reconstruir cómo evolucionó el *pipeline* comercial y ofrecen una fuente de datos para desarrollar pronósticos reproducibles.

En mercados de empresa a empresa o B2B (*business to business*), el modelado presenta dificultades particulares. La cantidad de operaciones suele ser menor que en contextos de consumo masivo, los montos son heterogéneos y unas pocas oportunidades de gran tamaño pueden modificar de manera significativa el total de un período. También son frecuentes los cambios en las fechas esperadas de cierre y en las valoraciones subjetivas del equipo comercial. Se han propuesto modelos de aprendizaje automático para estimar la probabilidad de éxito de oportunidades B2B a partir de la evolución del *pipeline* [2]. Otros trabajos utilizaron información comercial anticipada para mejorar procesos manuales de pronóstico en casos reales de ventas B2B [3].

El presente trabajo aborda una variante diferente y complementaria. En lugar de estimar únicamente la probabilidad de éxito de cada oportunidad, busca proyectar el volumen agregado de contrataciones, entendido como el monto de ventas efectivamente comprometidas durante un horizonte futuro. La salida sirve como apoyo para la planificación financiera trimestral y permite una comparación directa con el pronóstico utilizado por la organización.

1.2. Contexto y motivación

OceanSound Partners es una firma de inversión en empresas de tecnología y servicios habilitados por tecnología que atienden mercados gubernamentales y empresariales [4]. Una de las empresas de su portafolio administra la actividad comercial mediante un CRM en el que registra la evolución de sus oportunidades de venta. La planificación financiera depende, en buena medida, de la proyección de las contrataciones futuras.

Antes de este trabajo, esas proyecciones se elaboraban a partir del pronóstico almacenado en el CRM y de la evaluación manual del equipo comercial. El proceso dependía del criterio de las personas involucradas, era difícil de reproducir y no contaba con un procedimiento común para medir su error histórico. Esta situación dificultaba anticipar desvíos en los ingresos, asignar recursos con suficiente previsión y distinguir si una corrección provenía de nueva información comercial o de una apreciación subjetiva. Como consecuencia, la organización tenía menos capacidad para detectar de manera temprana necesidades de contratación, ajustes presupuestarios y oportunidades que requerían atención.

El CRM conserva una fotografía semanal, denominada *snapshot*, del estado completo del *pipeline*. Una misma oportunidad aparece en sucesivos *snapshots* con la información disponible en cada fecha. Esta estructura permite estudiar no solo el resultado final de una venta, sino también la evolución de las variables que podían observarse antes de que ese resultado ocurriera.

La motivación del trabajo surge de dos oportunidades. Desde la perspectiva organizacional, se busca disponer de un pronóstico cuantitativo, trazable y comparable con el método vigente. Desde la perspectiva académica, el problema permite integrar preparación y análisis de datos, aprendizaje automático, series temporales, validación de modelos y gestión de experimentos sobre un caso real.

1.3. Descripción del problema

El conjunto de datos tiene estructura de panel longitudinal: cada fila representa el estado de una oportunidad en una fecha de observación y una misma oportunidad se repite a lo largo de múltiples *snapshots*. Las contrataciones se determinan a partir de las oportunidades ganadas y de su fecha efectiva de cierre. Por esta razón, una agregación directa de todas las filas produciría duplicaciones y mezclaría estados conocidos en momentos diferentes.

El desafío metodológico principal consiste en respetar la disponibilidad temporal de la información. Para producir una proyección desde un instante T , las variables predictoras solo pueden utilizar datos que ya eran conocidos en ese instante. Incorporar el estado final de una oportunidad, su fecha de cierre efectiva o una transformación calculada con observaciones posteriores constituiría una fuga de

información o *data leakage*. Esta clase de error genera métricas artificialmente optimistas y un modelo que no puede reproducir su desempeño cuando se utiliza sobre períodos futuros.

La fuente combina así una gran cantidad de filas con una historia temporal relativamente corta. El problema requiere transformar los estados históricos del *pipeline* en observaciones comparables, definir un monto de contrataciones sin contar una misma oportunidad más de una vez y relacionar cada observación con un período futuro. También exige considerar que los meses recientes pueden contener oportunidades cuyo resultado definitivo todavía no se encontraba registrado. El diseño adoptado para resolver estas dificultades se presenta en el capítulo 3.

1.4. Estado del arte

El pronóstico de ventas puede abordarse mediante métodos estadísticos, modelos de aprendizaje automático, redes neuronales y estimaciones basadas en juicio experto. No existe un enfoque universalmente superior: el resultado depende de la cantidad de datos, su frecuencia, el horizonte de decisión, la estabilidad del proceso y la disponibilidad de variables explicativas.

1.4.1. Pronósticos estadísticos y basados en juicio experto

Los modelos autorregresivos integrados de media móvil o ARIMA (*Autoregressive Integrated Moving Average*) constituyen una referencia clásica para representar autocorrelación, tendencia y estacionalidad [5]. Su formulación es interpretable y puede resultar efectiva cuando la estructura histórica de la serie permanece relativamente estable. Como limitación para este trabajo, un modelo puramente univariado no utiliza directamente el estado actual de las oportunidades comerciales.

Prophet propone un modelo descomponible con tendencia, estacionalidades y eventos, acompañado por parámetros que pueden ser ajustados por un analista [6]. Fue concebido para facilitar el pronóstico de numerosas series de negocio y ofrece una referencia intermedia entre automatización e intervención humana. No obstante, tanto Prophet como ARIMA necesitan suficientes observaciones para identificar patrones temporales de manera confiable.

Los pronósticos basados en criterio comercial incorporan conocimiento que puede no estar codificado en los datos, pero su desempeño depende de cómo se realicen los ajustes. La evidencia muestra que algunos ajustes mejoran la precisión, mientras que otros la reducen y presentan sesgo optimista [1]. Por ese motivo, resulta necesario medir el valor agregado por la intervención humana y conservar el pronóstico del CRM como una referencia explícita.

1.4.2. Aprendizaje automático aplicado al embudo comercial

Los métodos basados en árboles permiten capturar relaciones no lineales e interacciones sin imponer una forma funcional única. Los bosques aleatorios o *Random Forest* reducen la varianza mediante la combinación de árboles construidos sobre muestras y subconjuntos aleatorios de variables [7]. XGBoost agrega árboles de manera secuencial mediante *gradient boosting* e incorpora regularización y optimizaciones para datos dispersos [8]. Ambos enfoques pueden utilizar rezagos

históricos junto con medidas agregadas del *pipeline*, aunque requieren control de complejidad cuando la cantidad de períodos es pequeña.

Las redes recurrentes LSTM (*Long Short Term Memory*) fueron diseñadas para aprender dependencias prolongadas mediante mecanismos de memoria y compuertas [9]. Su flexibilidad permite representar dinámicas temporales complejas, pero implica una cantidad mayor de parámetros y una necesidad de datos que puede resultar desfavorable en series empresariales cortas. En este contexto, su inclusión constituye una hipótesis que debe evaluarse y no una garantía de mejora.

En el dominio B2B se utilizaron modelos para estimar la probabilidad de éxito de oportunidades a partir de información temporal del *pipeline* [2]. También se aplicó aprendizaje supervisado a información comercial anticipada para complementar procesos manuales de pronóstico [3]. Estos antecedentes respaldan el uso de variables disponibles antes del cierre, aunque el objetivo del presente trabajo es el monto agregado de contrataciones y no la clasificación individual de oportunidades.

1.4.3. Agregación temporal

La agregación temporal transforma una serie de alta frecuencia en observaciones correspondientes a períodos más extensos. Esta operación atenúa variaciones de alta frecuencia y puede facilitar la identificación de tendencias y ciclos. La combinación de múltiples niveles de agregación permite mejorar la estimación de componentes estructurales de una serie [10]. También se observó que la agregación puede mejorar la precisión y reducir la incertidumbre en problemas de demanda, aunque disminuye la cantidad de observaciones disponibles [11].

Este compromiso es especialmente relevante para el caso estudiado. La frecuencia semanal proporciona más puntos de entrenamiento, pero puede exhibir una variabilidad elevada. La frecuencia mensual reduce parte de ese ruido, aunque deja una muestra pequeña, mientras que el horizonte trimestral coincide mejor con la decisión financiera. Por lo tanto, la granularidad constituye una dimensión que debe evaluarse empíricamente.

El enfoque adoptado compara referencias simples, el pronóstico del CRM, modelos estadísticos, algoritmos basados en árboles y una red LSTM bajo un protocolo temporal común. La contribución no reside en proponer un algoritmo nuevo, sino en construir un proceso reproducible que transforma estados históricos del *pipeline* en una proyección agregada, evita el uso de información futura y permite comparar familias de modelos sobre las mismas fechas y métricas.

1.5. Objetivos

El objetivo general del trabajo es desarrollar y evaluar un modelo de aprendizaje automático, integrado en un flujo de procesamiento de datos reproducible, para proyectar las contrataciones del trimestre siguiente a partir del estado mensual histórico de un CRM, con corrección temporal y un desempeño medido frente al pronóstico utilizado por la organización.

Dentro de los objetivos específicos se pueden mencionar los siguientes:

- Diseñar e implementar un flujo reproducible para ingerir, validar, limpiar y consolidar los *snapshots* históricos del CRM.
- Definir la variable objetivo de contrataciones y construir las variables predictoras con criterio *point in time*, de modo de evitar duplicaciones y fuga de información.
- Analizar el efecto de las granularidades semanal, mensual y trimestral sobre la variabilidad de la serie y la precisión de los pronósticos.
- Comparar modelos de referencia, ARIMA, Prophet, *Random Forest*, XGBoost y LSTM mediante una metodología común de validación temporal y métricas homogéneas.
- Seleccionar y ajustar el modelo de mejor desempeño y cuantificar su diferencia respecto del pronóstico del CRM.
- Generar proyecciones trimestrales agregadas, trazables e interpretables que puedan utilizarse como apoyo en la planificación financiera.

1.6. Alcance del trabajo

El trabajo comprende el desarrollo de un prototipo funcional orientado a demostrar la factibilidad técnica y el valor práctico del enfoque. El alcance incluye la carga y validación de archivos históricos exportados desde el CRM, la consolidación de los *snapshots*, la construcción de una tabla mensual de modelado, la definición de las contrataciones, la generación de variables, el entrenamiento y comparación de diferentes familias de modelos, el registro de experimentos y la exportación de proyecciones y métricas.

Quedan fuera del alcance la conexión en tiempo real con el CRM, el desarrollo de una interfaz de usuario, el despliegue productivo y el modelado financiero posterior a la proyección. Tampoco se realiza una segmentación geográfica, debido a que la fuente disponible no contiene una dimensión de región. El trabajo se desarrolla dentro de la infraestructura autorizada por la organización. La documentación académica utiliza descripciones, métricas y resultados agregados, sin publicar nombres de clientes, contactos ni datos crudos que permitan identificar personas u oportunidades comerciales.

Capítulo 2

Introducción específica

En este capítulo se presentan los datos, los modelos, las métricas y los recursos tecnológicos utilizados en el trabajo. Primero se caracteriza la fuente histórica proveniente del sistema de gestión comercial y se describen sus variables, su calidad y sus limitaciones. Luego se define la salida esperada y se resumen los enfoques de pronóstico considerados. Finalmente, se detallan las métricas de evaluación, las bibliotecas y la infraestructura de cómputo. Las decisiones de diseño e implementación se reservan para el capítulo 3, mientras que los ensayos y sus resultados se presentan en el capítulo 4.

2.1. Conjunto de datos

La fuente principal fue una exportación histórica del CRM de una empresa del portafolio de OceanSound Partners. El archivo contenía fotografías sucesivas del embudo comercial. Cada fotografía, denominada *snapshot*, registraba el estado conocido de las oportunidades en una fecha determinada. Una misma oportunidad podía aparecer en numerosos períodos consecutivos, por lo que la cantidad de filas no representaba la cantidad de operaciones independientes.

La extracción reducida reunió 1.993.467 filas y 23 columnas, con un tamaño aproximado de 498 MB. El período observado se extendió desde el 8 de enero de 2024 hasta el 1 de junio de 2026 y comprendió 126 *snapshots* separados por una cadencia exacta de siete días. En total se identificaron 24.828 oportunidades, 4.476 cuentas y 225 responsables comerciales. Cada oportunidad apareció, en promedio, en 80,29 fotografías.

La tabla 2.1 resume las principales dimensiones de la fuente.

TABLA 2.1. Resumen del conjunto de datos utilizado en el trabajo.

Propiedad	Valor
Filas	1.993.467
Columnas	23
Tamaño aproximado del archivo	498 MB
Fotografías semanales	126
Primera fecha observada	8 de enero de 2024
Última fecha observada	1 de junio de 2026
Oportunidades únicas	24.828
Cuentas únicas	4.476
Responsables comerciales únicos	225
Apariciones promedio por oportunidad	80,29

2.1.1. Estructura y variables disponibles

La fuente tuvo una estructura de panel longitudinal. La fecha de cada fotografía indicó el instante en el que la información se encontraba disponible y el identificador de oportunidad permitió seguir una misma operación a lo largo del tiempo. Las columnas restantes describieron el estado comercial, las fechas relevantes, los montos, la probabilidad de cierre, la categoría de pronóstico y los responsables asociados.

Las variables monetarias incluyeron el valor contractual anual, los servicios profesionales y los componentes de equipamiento o licencias. También se dispuso del monto total de la oportunidad, de componentes esperados y del ingreso esperado registrado por el CRM. Los importes ya se encontraban expresados en dólares estadounidenses, por lo que no fue necesario realizar conversiones monetarias.

El estado de una oportunidad se representó mediante indicadores de cierre y resultado. Estos campos se consideraron más confiables que el nombre textual de la etapa, porque este último presentaba variantes semánticas e inconsistencias. La fecha prevista de cierre, la fecha de creación, la procedencia del contacto, el tipo de oportunidad y la categoría del pronóstico completaron la descripción comercial disponible.

La fuente contenía información suficiente para observar dos aspectos diferentes. Por una parte, permitía reconstruir el volumen y la valoración de las oportunidades que se encontraban abiertas en una fecha. Por otra, permitía identificar las operaciones que finalmente habían sido ganadas y asignarlas a su fecha efectiva de cierre. La forma en que ambas perspectivas se consolidaron sin duplicaciones ni uso de información futura se explica en el capítulo 3.

2.1.2. Contrataciones históricas

El monto contratado se definió como la suma del valor contractual anual, los servicios profesionales y los componentes de equipamiento o licencias de las oportunidades ganadas. Se comprobó que esta suma coincidía con el monto total registrado, con una tolerancia de un dólar, para la totalidad de las operaciones consolidadas.

La historia disponible comprendió 11.983 oportunidades ganadas con fechas de cierre entre el 3 de enero de 2023 y el 29 de mayo de 2026. El monto acumulado fue de USD 186.782.760. Los servicios profesionales representaron el 73,3 por ciento, el valor contractual anual el 17,7 por ciento y los componentes de equipamiento o licencias el 9,0 por ciento restante. Esta composición mostró que la mayor parte del volumen provenía de servicios, aunque se preservó el desglose para facilitar su análisis posterior.

La cantidad de operaciones y sus montos variaron de manera considerable entre períodos. Un conjunto reducido de oportunidades de valor elevado podía modificar el total de un mes. Por este motivo, el análisis debía considerar tanto el error monetario como el error relativo y no podía apoyarse únicamente en el porcentaje de aciertos individuales.

2.1.3. Calidad, limitaciones y confidencialidad

La calidad general de las variables centrales resultó adecuada. Los valores faltantes se concentraron principalmente en la procedencia del contacto, con un 2,36 por ciento. Los identificadores de responsable y el tipo de oportunidad presentaron proporciones inferiores al 0,15 por ciento. También se detectaron 66 filas sin contenido útil en los campos principales.

La principal limitación fue la longitud temporal efectiva. Los casi dos millones de registros correspondían a repeticiones de oportunidades observadas durante menos de dos años y medio. En consecuencia, la cantidad de ejemplos útiles para comparar pronósticos temporales fue mucho menor que el número de filas originales. Esta característica condicionó la complejidad admisible de los modelos y la solidez de las estimaciones sobre períodos recientes.

Los últimos meses presentaron además censura por la derecha. Algunas oportunidades continuaban abiertas al momento de realizar la extracción y todavía podían cambiar de estado. La fuente tampoco incluyó una variable de región, por lo que no permitió evaluar pronósticos geográficos sin incorporar información externa.

Los datos crudos se procesaron dentro de la infraestructura autorizada por la organización y no se incorporaron al repositorio académico. La memoria utiliza únicamente conteos, proporciones, métricas y resultados agregados. No se publican nombres de personas, clientes u oportunidades, ni valores que permitan reconstruir una operación individual.

2.2. Salida esperada e información predictiva

La salida esperada es el monto total de contrataciones del trimestre siguiente a cada origen mensual. Si B_{T+k} representa el monto contratado en el mes situado k períodos después del origen T , el objetivo trimestral q_T se expresa mediante la ecuación 2.1.

$$q_T = \sum_{k=1}^3 B_{T+k}. \quad (2.1)$$

Esta definición coincide con el horizonte utilizado por la planificación financiera y permite comparar la estimación automática con el pronóstico comercial. La observación de entrada representa la información disponible en el origen, mientras que la salida corresponde a los tres meses posteriores.

La información predictiva se organizó en tres grupos conceptuales. El primero describió el embudo comercial abierto mediante la cantidad de oportunidades, su monto total, su valor ponderado por probabilidad y el ingreso esperado. El segundo representó la historia de las contrataciones mediante valores anteriores y resúmenes móviles. El tercero describió la posición temporal de cada observación dentro del año.

Esta sección define qué información se encontró disponible y cuál fue la salida de interés. La selección de la fotografía mensual, la consolidación de oportunidades, la construcción de las variables y la prevención de fuga de información corresponden al diseño del sistema y se desarrollan en el capítulo 3.

2.3. Modelos considerados

El trabajo consideró modelos con diferentes supuestos y niveles de complejidad. Se incluyeron referencias simples para determinar si los métodos más elaborados aportaban una mejora real. Una referencia repitió el último valor observado y otra utilizó el valor correspondiente al mismo período del año anterior. El pronóstico ponderado del CRM se mantuvo como referencia de negocio.

Entre los modelos de series temporales se utilizaron ARIMA y Prophet. ARIMA representó la dependencia histórica mediante componentes autorregresivos, de integración y de media móvil [5]. Prophet aportó una formulación descomponible de tendencia y estacionalidad [6]. Ambos métodos utilizaron la historia agregada de contrataciones como entrada.

Los modelos tabulares fueron *Random Forest* y XGBoost. El primero combinó múltiples árboles de regresión contruidos con aleatoriedad en observaciones y variables [7]. El segundo utilizó árboles incorporados secuencialmente mediante *boosting* y mecanismos de regularización [8]. Estos enfoques permitieron combinar la historia de contrataciones con variables agregadas del embudo comercial.

También se incluyó una red recurrente LSTM (*Long Short Term Memory*) como alternativa para representar dependencias temporales [9]. La diversidad de métodos permitió contrastar referencias de baja complejidad, modelos estadísticos, algoritmos de árboles y una red neuronal. Las configuraciones, el procedimiento de entrenamiento y las reglas de comparación se detallan en el capítulo 3. Los resultados obtenidos por cada enfoque se reservan para el capítulo 4.

La tabla 2.2 resume las familias consideradas y sus implementaciones.

TABLA 2.2. Familias de modelos y bibliotecas utilizadas.

Familia	Implementación	Información principal
Referencias simples	pandas y NumPy	Historia de contrataciones
Pronóstico del CRM	Estimador propio	Embudo comercial ponderado
ARIMA	statsmodels	Historia de contrataciones
Prophet	Prophet	Historia de contrataciones
<i>Random Forest</i>	scikit learn	Historia y embudo comercial
XGBoost	XGBoost	Historia y embudo comercial
LSTM	PyTorch	Secuencia de contrataciones

2.4. Métricas de evaluación

La evaluación utilizó métricas absolutas, cuadráticas, porcentuales y de ajuste. Para n observaciones, donde y_t es el monto real y $\hat{y}_t$ es el monto proyectado, el error absoluto medio o MAE (*Mean Absolute Error*) y la raíz del error cuadrático medio o RMSE (*Root Mean Squared Error*) se definen en las ecuaciones 2.2 y 2.3.

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|. \quad (2.2)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}. \quad (2.3)$$

El MAE expresa el desvío promedio en unidades monetarias y mantiene una interpretación directa. El RMSE asigna mayor peso a los errores grandes debido al término cuadrático. Esta propiedad resulta útil cuando se desea identificar modelos sensibles a meses con desvíos extraordinarios.

El error porcentual absoluto medio o MAPE (*Mean Absolute Percentage Error*) expresa el error medio como porcentaje de cada observación, pero no se encuentra definido cuando el valor real es cero y puede crecer de manera desproporcionada ante valores pequeños [12]. El error porcentual absoluto ponderado o WAPE (*Weighted Absolute Percentage Error*) divide la suma de los errores absolutos por el volumen real acumulado. Ambas métricas se definen en las ecuaciones 2.4 y 2.5.

$$\text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|. \quad (2.4)$$

$$\text{WAPE} = 100 \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n |y_t|}. \quad (2.5)$$

El WAPE evita la división individual por valores nulos y pondera cada período de acuerdo con su aporte al total. Por esta razón fue la métrica principal del trabajo.

El coeficiente de determinación R^2 complementó las métricas de error y se calculó mediante la ecuación 2.6.

$$R^2 = 1 - \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y})^2}, \quad (2.6)$$

donde $\bar{y}$ representa el promedio de los valores reales. Un valor cercano a uno indica que el modelo representa una proporción elevada de la variabilidad observada. Un valor negativo señala que su desempeño es inferior al de una predicción constante basada en el promedio. Las reglas temporales utilizadas para obtener las predicciones evaluadas se presentan en el capítulo 3.

2.5. Entorno tecnológico

El trabajo se desarrolló en Python 3.11 o superior. pandas y NumPy se utilizaron para la lectura, la transformación tabular, las agregaciones temporales y los cálculos numéricos. PyArrow permitió almacenar las tablas procesadas en un formato columnar y Pandera se empleó para declarar controles sobre el esquema de entrada.

scikit learn proporcionó los modelos y contratos comunes de aprendizaje automático. XGBoost se utilizó para el modelo de *boosting*, statsmodels para ARIMA, Prophet para el modelo descomponible y PyTorch para la red LSTM. MLflow permitió registrar los parámetros y las métricas de los experimentos en una base SQLite local.

Matplotlib y Seaborn se utilizaron para producir gráficos. Joblib permitió serializar el modelo seleccionado y un archivo JSON conservó sus metadatos. pytest se empleó para las pruebas automatizadas y Ruff para el control estático del código. La tabla 2.3 resume el propósito de las herramientas principales.

TABLA 2.3. Herramientas principales del entorno tecnológico.

Herramienta	Uso dentro del trabajo
Python, pandas y NumPy	Procesamiento tabular y cálculo numérico
PyArrow y Pandera	Persistencia columnar y validación del esquema
scikit learn y XGBoost	Modelos tabulares
statsmodels y Prophet	Modelos de series temporales
PyTorch	Red neuronal recurrente
MLflow y SQLite	Registro local de experimentos
Matplotlib y Seaborn	Generación de gráficos
Joblib y JSON	Persistencia del modelo y sus metadatos
pytest y Ruff	Pruebas automatizadas y control estático

La organización interna del código, la secuencia de procesamiento y los mecanismos de persistencia forman parte de la implementación. Por ese motivo, se desarrollan en el capítulo 3 y no se detallan en esta introducción específica.

2.6. Infraestructura de cómputo

El desarrollo y los experimentos se ejecutaron de forma local sobre un equipo con arquitectura *Apple Silicon* y 24 GiB de memoria. Los modelos basados en árboles y los métodos estadísticos utilizaron el procesador central. La implementación de LSTM pudo aprovechar la aceleración provista por *Metal Performance Shaders* cuando ese recurso se encontraba disponible.

Después de optimizar los tipos de datos, la tabla cargada ocupó aproximadamente 228 MB de memoria. El volumen de la extracción pudo procesarse sin infraestructura distribuida ni servicios externos de cómputo. Este entorno fue suficiente para el desarrollo y la evaluación del prototipo.

El alcance no incluyó un servicio de inferencia, una interfaz de usuario ni una conexión directa con el CRM. Las salidas del trabajo consistieron en archivos de proyección, métricas, figuras y un modelo serializado. En consecuencia, la infraestructura descrita corresponde a un entorno de desarrollo y evaluación. Los requisitos de una operación productiva, como disponibilidad, monitoreo y actualización automática, quedan fuera del alcance.

En síntesis, este capítulo caracteriza los insumos y recursos utilizados sin anticipar las decisiones de implementación ni los resultados. La fuente aporta una historia detallada del embudo comercial, los modelos cubren enfoques de distinta complejidad y las métricas permiten evaluar el error desde perspectivas complementarias. El capítulo siguiente presenta cómo estos elementos se integraron en el diseño del sistema.

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

Se puede agregar código o pseudocódigo dentro de un entorno `lstlisting` con el siguiente código:

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
las líneas de código irían aquí...
\end{lstlisting}
```

A modo de ejemplo, se muestra el fragmento de código [3.1](#):

```
1 #define MAX_SENSOR_NUMBER 3
2 #define MAX_ALARM_NUMBER 6
3 #define MAX_ACTUATOR_NUMBER 6
4
5 uint32_t sensorValue[MAX_SENSOR_NUMBER];
6 FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
7 state_t alarmState[MAX_ALARM_NUMBER]; //ON or OFF
8 state_t actuatorState[MAX_ACTUATOR_NUMBER]; //ON or OFF
9
10 void vControl() {
11
12     initGlobalVariables();
13
14     period = 500 ms;
15
16     while(1) {
17
18         ticks = xTaskGetTickCount();
19
20         updateSensors();
21
22         updateAlarms();
23
24         controlActuators();
25
26         vTaskDelayUntil(&ticks, period);
27     }
```

28 }

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] Robert Fildes y col. «Effective Forecasting and Judgmental Adjustments: An Empirical Evaluation and Strategies for Improvement in Supply Chain Planning». En: *International Journal of Forecasting* 25.1 (2009), págs. 3-23. DOI: [10.1016/j.ijforecast.2008.11.010](https://doi.org/10.1016/j.ijforecast.2008.11.010).
- [2] Junchi Yan y col. «On Machine Learning towards Predictive Sales Pipeline Analytics». En: *Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence*. Vol. 29. 1. 2015. DOI: [10.1609/aaai.v29i1.9455](https://doi.org/10.1609/aaai.v29i1.9455).
- [3] D. Rohaan, E. Topan y C. G. M. Groothuis-Oudshoorn. «Using Supervised Machine Learning for B2B Sales Forecasting: A Case Study of Spare Parts Sales Forecasting at an After Sales Service Provider». En: *Expert Systems with Applications* 188 (2022), pág. 115925. DOI: [10.1016/j.eswa.2021.115925](https://doi.org/10.1016/j.eswa.2021.115925).
- [4] OceanSound Partners. *OceanSound Partners*. 2026. URL: <https://oceansoundpartners.com/> (visitado 07-09-2026).
- [5] George E. P. Box y col. *Time Series Analysis: Forecasting and Control*. 5.^a ed. John Wiley & Sons, 2015. ISBN: 9781118675021.
- [6] Sean J. Taylor y Benjamin Letham. «Forecasting at Scale». En: *The American Statistician* 72.1 (2018), págs. 37-45. DOI: [10.1080/00031305.2017.1380080](https://doi.org/10.1080/00031305.2017.1380080).
- [7] Leo Breiman. «Random Forests». En: *Machine Learning* 45.1 (2001), págs. 5-32. DOI: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [8] Tianqi Chen y Carlos Guestrin. «XGBoost: A Scalable Tree Boosting System». En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, págs. 785-794. DOI: [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- [9] Sepp Hochreiter y Jürgen Schmidhuber. «Long Short Term Memory». En: *Neural Computation* 9.8 (1997), págs. 1735-1780. DOI: [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).
- [10] Nikolaos Kourentzes, Fotios Petropoulos y Juan R. Trapero. «Improving Forecasting by Estimating Time Series Structural Components Across Multiple Frequencies». En: *International Journal of Forecasting* 30.2 (2014), págs. 291-302. DOI: [10.1016/j.ijforecast.2013.09.006](https://doi.org/10.1016/j.ijforecast.2013.09.006).
- [11] Nikolaos Kourentzes, Bahman Rostami-Tabar y Devon K. Barrow. «Demand Forecasting by Temporal Aggregation: Using Optimal or Multiple Aggregation Levels?». En: *Journal of Business Research* 78 (2017), págs. 1-9. DOI: [10.1016/j.jbusres.2017.04.016](https://doi.org/10.1016/j.jbusres.2017.04.016).
- [12] Rob J. Hyndman y Anne B. Koehler. «Another Look at Measures of Forecast Accuracy». En: *International Journal of Forecasting* 22.4 (2006), págs. 679-688. DOI: [10.1016/j.ijforecast.2006.03.001](https://doi.org/10.1016/j.ijforecast.2006.03.001).