

Predicción de ventas con técnicas de machine learning aplicadas a series temporales de contrataciones

Mg. Juan Pablo Skobalski

Carrera de Especialización en Inteligencia Artificial

Director: Mg. Juan Cruz Skobalski

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Buenos Aires, junio de 2026

Resumen

En este trabajo se desarrolló un modelo de aprendizaje automático, junto con un flujo de procesamiento de datos reproducible, para proyectar las contrataciones de una empresa a partir de fotografías semanales históricas de su sistema de gestión comercial. Para el modelado se seleccionó el primer snapshot de cada mes y se definió como objetivo el monto de las contrataciones de los tres meses siguientes. El propósito fue reemplazar las estimaciones manuales y subjetivas utilizadas hasta el momento por proyecciones basadas en evidencia, reproducibles y trazables, que sirvieran de apoyo a la planificación financiera de la organización. Para ello se construyó un conjunto de datos respetando la correcta separación temporal de la información, de modo de evitar que el modelo utilizara datos posteriores a la fecha de cada proyección, se compararon distintos enfoques de modelado, que abarcaron regresión, series temporales y redes neuronales, bajo una metodología de validación temporal común, y se seleccionó y ajustó el de mejor desempeño. El modelo resultante redujo el error de proyección y superó de manera consistente al método manual tomado como referencia. La memoria presenta el contexto y la formulación del problema, el marco teórico, el diseño e implementación del flujo de trabajo y de los modelos, los ensayos realizados con sus resultados, y las conclusiones. En el proyecto se aplicaron de manera integrada contenidos de la especialización, entre ellos el análisis y la preparación de datos, el aprendizaje automático, las series temporales y la evaluación de modelos.

Índice general

Resumen	I
1. Introducción general	1
1.1. Introducción general al tema	1
1.2. Contexto y motivación	2
1.3. Descripción del problema	2
1.4. Estado del arte	3
1.4.1. Pronósticos estadísticos y basados en juicio experto	4
1.4.2. Aprendizaje automático aplicado al pipeline comercial	4
1.4.3. Agregación temporal y evaluación	5
1.5. Objetivos	5
1.5.1. Objetivo general	5
1.5.2. Objetivos específicos	5
1.6. Alcance del proyecto	6
1.7. Organización de la memoria	7
2. Introducción específica	9
2.1. Estilo y convenciones	9
2.1.1. Uso de mayúscula inicial para los título de secciones	9
2.1.2. Este es el título de una subsección	9
2.1.3. Figuras	10
2.1.4. Tablas	11
2.1.5. Ecuaciones	12
3. Diseño e implementación	13
3.1. Análisis del software	13
4. Ensayos y resultados	15
4.1. Pruebas funcionales del hardware	15
5. Conclusiones	17
5.1. Conclusiones generales	17
5.2. Próximos pasos	17

Índice de figuras

2.1. Ilustración del cuadrado azul que se eligió para el diseño del logo.	10
2.2. Imagen tomada de la página oficial del procesador ¹	11
2.3. ¿Por qué de pronto aparece esta figura?	11
2.4. Tres gráficos simples.	11

Índice de tablas

1.1. Comparación de los principales enfoques de pronóstico considerados. Las ventajas y limitaciones se expresan para un pipeline B2B con una historia temporal reducida y montos heterogéneos.	6
2.1. caption corto	12

Capítulo 1

Introducción general

En este capítulo se introduce el problema de la proyección de contrataciones a partir de información comercial histórica. Se presenta primero el rol que cumple el pronóstico de ventas en la planificación de una organización y luego se describe el contexto que motivó el trabajo. A continuación, se formula el problema técnico, se revisan los principales enfoques propuestos en la literatura y se establece la posición adoptada en el proyecto. Finalmente, se enuncian los objetivos, el alcance y la organización de la memoria.

1.1. Introducción general al tema

La proyección de ventas constituye un insumo central para la planificación financiera de una organización. A partir de ella se estiman ingresos, se asignan recursos, se definen metas y se anticipan necesidades de capacidad. En entornos empresariales, esta tarea suele combinar información histórica con el conocimiento de los responsables comerciales. Los sistemas de pronóstico brindan una base cuantitativa, mientras que las personas incorporan información contextual que no siempre se encuentra representada en los datos. Sin embargo, los ajustes basados en juicio experto no mejoran necesariamente la precisión y pueden introducir sesgos, en particular cuando son frecuentes, pequeños o excesivamente optimistas.

Los sistemas de gestión de relaciones con clientes o CRM (Customer Relationship Management) registran de manera estructurada la actividad comercial. Para cada oportunidad pueden almacenar su monto esperado, la probabilidad estimada de cierre, la etapa dentro del proceso de venta, la fecha prevista de concreción y otras características relevantes. Además de facilitar el seguimiento operativo, estos registros permiten reconstruir cómo evolucionó el pipeline comercial y ofrecen una fuente de datos para desarrollar pronósticos reproducibles.

En mercados de empresa a empresa o B2B (business to business), el modelado presenta dificultades particulares. La cantidad de operaciones suele ser menor que en contextos de consumo masivo, los montos son heterogéneos y unas pocas oportunidades de gran tamaño pueden modificar de manera significativa el total de un período. También son frecuentes los cambios en las fechas esperadas de cierre y en las valoraciones subjetivas del equipo comercial. En este tipo de contextos es posible utilizar aprendizaje automático para estimar la probabilidad de éxito de oportunidades B2B, aunque el reducido número de transacciones, el ruido y

la evolución del entorno de negocios limitan el modelado. La información comercial anticipada también puede emplearse para mejorar los procesos manuales de pronóstico de ventas B2B.

Este trabajo abordó una variante diferente y complementaria del problema. En lugar de estimar únicamente la probabilidad de éxito de cada oportunidad, se buscó proyectar el volumen agregado de contrataciones, es decir, el monto de ventas efectivamente comprometidas durante un horizonte futuro. La salida se diseñó para apoyar la planificación financiera trimestral y, por lo tanto, para poder compararse con el pronóstico que la organización utilizaba como referencia.

1.2. Contexto y motivación

OceanSound Partners es una firma de inversión que gestiona un portafolio de empresas. Una de las empresas de ese portafolio administra su actividad comercial mediante un CRM, en el que registra la evolución de sus oportunidades de venta. La planificación financiera depende, en buena medida, de la proyección de las contrataciones futuras. Antes de este proyecto, esas proyecciones se elaboraban a partir del pronóstico almacenado en el CRM y de la evaluación manual del equipo comercial. El proceso dependía del criterio de las personas involucradas, era difícil de reproducir y no contaba con un procedimiento común para medir su error histórico.

El CRM conserva una fotografía semanal, denominada en adelante snapshot, del estado completo del pipeline. Una misma oportunidad aparece en sucesivos snapshots con la información disponible en cada fecha. Esta estructura permite estudiar no solo el resultado final de una venta, sino también la evolución de las variables que estaban disponibles antes de que ese resultado ocurriera.

La frecuencia semanal brinda un registro detallado, pero no necesariamente coincide con el horizonte relevante para la decisión de negocio. Durante el desarrollo se comprobó que las contrataciones semanales presentaban una variabilidad elevada y que los errores de proyección disminuían al trabajar con períodos más agregados. En consecuencia, se seleccionó el primer snapshot disponible de cada mes como punto de observación y se definió como variable objetivo la suma de las contrataciones de los tres meses posteriores. De este modo, se mantuvo la información histórica de origen, pero se alineó la frecuencia de modelado con la planificación trimestral.

La motivación del trabajo surgió, por lo tanto, de dos oportunidades. Desde la perspectiva organizacional, se buscó disponer de un pronóstico cuantitativo, trazable y comparable con el método vigente. Desde la perspectiva académica, el problema permitió integrar preparación y análisis de datos, aprendizaje automático, series temporales, validación de modelos y gestión de experimentos sobre un caso real.

1.3. Descripción del problema

El conjunto de datos tiene estructura de panel longitudinal: cada fila representa el estado de una oportunidad en una fecha de observación y una misma oportunidad se repite a lo largo de múltiples snapshots. Las contrataciones se determinan

a partir de las oportunidades ganadas y de su fecha efectiva de cierre. Por esta razón, el conjunto utilizado para modelar no puede construirse mediante una agregación directa de todas las filas, ya que ello produciría duplicaciones y mezclaría estados conocidos en distintos momentos.

El desafío metodológico principal consiste en respetar la disponibilidad temporal de la información. Para producir una proyección desde un instante T , las variables predictoras solo pueden utilizar datos que ya eran conocidos en ese instante. Incorporar el estado final de una oportunidad, su fecha de cierre efectiva o cualquier transformación calculada con observaciones posteriores constituiría una fuga de información o data leakage. Este problema produce métricas artificialmente optimistas y un modelo que no puede reproducir su desempeño cuando se utiliza sobre períodos futuros.

La construcción del conjunto supervisado requiere entonces tres operaciones fundamentales. Primero, se debe consolidar cada snapshot sin perder su condición point in time. Segundo, se debe construir el monto de contrataciones evitando contar una misma oportunidad más de una vez. Tercero, cada estado mensual del pipeline debe asociarse con las contrataciones acumuladas durante los tres meses siguientes. Los períodos más recientes necesitan, además, un tratamiento específico, porque algunas operaciones todavía no habían alcanzado su resultado definitivo al momento de extraer los datos; esta condición se denomina censura por la derecha.

La evaluación también debe conservar el orden cronológico. Una partición aleatoria permitiría que observaciones futuras participaran en el entrenamiento de predicciones correspondientes al pasado. Para evitarlo, la selección de modelos se planteó mediante validación temporal de ventana expansiva o walk forward, en la que cada iteración entrena con la historia disponible y evalúa sobre un período posterior. La evaluación de predictores temporales requiere procedimientos diferentes de la validación cruzada convencional, precisamente por la dependencia y la evolución temporal de los datos.

La métrica relativa principal es el error porcentual absoluto ponderado o WAPE (Weighted Absolute Percentage Error), definido por la ecuación 1.1.

$$\text{WAPE} = 100 \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n |y_t|}, \quad (1.1)$$

donde y_t es el monto real y $\hat{y}_t$ es el monto proyectado para el período t . A diferencia del error porcentual absoluto medio o MAPE (Mean Absolute Percentage Error), el WAPE no divide cada error por una observación individual. Esto evita valores indefinidos cuando un período no registra contrataciones. Las métricas porcentuales presentan limitaciones ante valores nulos o cercanos a cero. El WAPE se complementa con el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2), de modo de analizar tanto la magnitud como la distribución de los errores.

1.4. Estado del arte

El pronóstico de ventas puede abordarse mediante métodos estadísticos, modelos de aprendizaje automático, redes neuronales y estimaciones basadas en juicio

experto. No existe un enfoque universalmente superior: el resultado depende de la cantidad de datos, su frecuencia, el horizonte de decisión, la estabilidad del proceso y la disponibilidad de variables explicativas.

1.4.1. Pronósticos estadísticos y basados en juicio experto

Los modelos autorregresivos integrados de media móvil o ARIMA (Autoregressive Integrated Moving Average) representan una referencia clásica para modelar autocorrelación, tendencia y estacionalidad. Su formulación resulta interpretable y puede ser efectiva cuando la estructura histórica de la serie es relativamente estable. Como limitación, un modelo puramente univariado no utiliza directamente el estado actual de las oportunidades comerciales.

Prophet propone un modelo descomponible con tendencia, estacionalidades y eventos, acompañado por parámetros que pueden ser ajustados por un analista. Este enfoque fue diseñado para facilitar el pronóstico de numerosas series de negocio y ofrece una referencia intermedia entre la automatización y la intervención humana. Sin embargo, tanto Prophet como ARIMA necesitan una cantidad suficiente de observaciones para identificar patrones temporales de manera confiable.

Los pronósticos basados en el criterio comercial incorporan conocimiento que puede no estar codificado en los datos, pero su desempeño depende de cómo se realicen los ajustes. Determinados ajustes pueden mejorar la precisión, mientras que otros pueden reducirla y mostrar un sesgo optimista. Esto respalda la necesidad de medir el valor agregado por la intervención humana y de conservar el pronóstico del CRM como una referencia explícita, en lugar de asumir de antemano que el modelo automático será mejor.

1.4.2. Aprendizaje automático aplicado al pipeline comercial

Los métodos basados en árboles permiten combinar variables numéricas y categóricas, capturar relaciones no lineales y representar interacciones sin imponer una forma funcional única. Los bosques aleatorios o Random Forest reducen la varianza mediante la combinación de múltiples árboles construidos sobre muestras y subconjuntos aleatorios de variables. XGBoost utiliza árboles agregados secuencialmente mediante gradient boosting e incorpora regularización y optimizaciones para datos dispersos. Ambos enfoques resultan adecuados para construir un problema supervisado a partir de rezagos históricos y medidas agregadas del pipeline.

Las redes recurrentes LSTM (Long Short Term Memory) fueron diseñadas para aprender dependencias de largo plazo mediante mecanismos de memoria y compuertas. Su flexibilidad permite representar dinámicas temporales complejas, pero implica un número mayor de parámetros y una necesidad de datos que puede resultar desfavorable en series empresariales cortas. Por ese motivo, su inclusión en una comparación debe entenderse como una hipótesis a evaluar y no como una garantía de mejora.

En el dominio B2B se han utilizado modelos para estimar la probabilidad de éxito de las oportunidades a partir de información del pipeline. Estas aplicaciones deben considerar especialmente los problemas de escasez y ruido de los datos. El aprendizaje supervisado puede aprovechar información comercial anticipada

para complementar un proceso manual. Estos antecedentes respaldan el uso de variables disponibles antes del cierre, aunque el objetivo del presente trabajo es el monto agregado de contrataciones y no la clasificación individual de oportunidades.

1.4.3. Agregación temporal y evaluación

La agregación temporal transforma una serie de alta frecuencia en observaciones correspondientes a períodos más extensos. Esta operación actúa como un filtro que atenúa componentes de alta frecuencia y puede facilitar la identificación de tendencias y ciclos. La combinación de información de múltiples niveles de agregación puede mejorar la estimación de la estructura temporal. La agregación también puede mejorar la precisión y reducir la incertidumbre de modelado en problemas de demanda, aunque disminuye la cantidad de observaciones disponibles.

Este compromiso es especialmente relevante en el caso estudiado. La frecuencia semanal proporciona más puntos de entrenamiento, pero exhibe una variabilidad elevada; la frecuencia mensual reduce el ruido, aunque deja una muestra pequeña; y el horizonte trimestral coincide mejor con la decisión financiera. En consecuencia, la granularidad se consideró un componente del problema de modelado y fue evaluada empíricamente, en lugar de fijarse únicamente por la frecuencia de extracción del CRM.

La tabla 1.1 resume las familias de enfoques consideradas y su relación con el problema abordado.

El enfoque adoptado combinó elementos de estas líneas de trabajo. Se compararon métodos de referencia, modelos estadísticos, algoritmos basados en árboles y una red LSTM bajo un protocolo temporal común. El pronóstico del CRM se mantuvo como referencia de negocio. La contribución no residió en proponer un algoritmo nuevo, sino en construir un proceso reproducible que transformó estados históricos del pipeline en un problema de proyección trimestral, evitó el uso de información futura y permitió comparar familias de modelos con las mismas fechas y métricas.

1.5. Objetivos

1.5.1. Objetivo general

Desarrollar y evaluar un modelo de aprendizaje automático, integrado en un pipeline de datos reproducible, para proyectar las contrataciones del trimestre siguiente a partir del estado mensual histórico de un CRM, con corrección temporal y un desempeño medido frente al pronóstico utilizado por la organización.

1.5.2. Objetivos específicos

- Diseñar e implementar un pipeline reproducible para ingerir, validar, limpiar y consolidar los snapshots históricos del CRM.
- Definir la variable objetivo de contrataciones y construir las variables predictoras con criterio point in time, de modo de evitar duplicaciones y fuga de información.

TABLA 1.1. Comparación de los principales enfoques de pronóstico considerados. Las ventajas y limitaciones se expresan para un pipeline B2B con una historia temporal reducida y montos heterogéneos.

Enfoque	Ventajas	Limitaciones y relación con el trabajo
Pronóstico del CRM y juicio experto	Incorpora conocimiento comercial y constituye la referencia utilizada por la organización.	Puede ser subjetivo, difícil de reproducir y susceptible a sesgos; se utiliza como línea de base de negocio.
ARIMA y Prophet	Representan tendencia y estacionalidad con modelos interpretables.	Aprovechan principalmente la historia de la serie y requieren suficientes períodos para estimar patrones estables.
Random Forest y XGBoost	Capturan no linealidades e interacciones entre rezagos y variables agregadas del pipeline.	Pueden sobreajustarse cuando el número de períodos es pequeño; requieren validación temporal y control de complejidad.
LSTM	Puede aprender dependencias temporales complejas sin especificarlas de forma manual.	Su mayor cantidad de parámetros puede ser inadecuada para una serie corta y ruidosa.
Agregación temporal	Reduce variaciones de alta frecuencia y alinea el pronóstico con el horizonte de decisión.	Suaviza la serie, pero reduce la cantidad de observaciones; el nivel debe validarse empíricamente.

- Analizar el efecto de la granularidad semanal, mensual y trimestral sobre la variabilidad de la serie y la precisión de los pronósticos.
- Comparar modelos de referencia, ARIMA, Prophet, Random Forest, XGBoost y LSTM mediante una metodología común de validación temporal y métricas homogéneas.
- Seleccionar y ajustar el modelo de mejor desempeño, y cuantificar su diferencia respecto del pronóstico del CRM mediante WAPE y métricas complementarias.
- Generar proyecciones trimestrales agregadas, trazables e interpretables que puedan utilizarse como apoyo en la planificación financiera.

1.6. Alcance del proyecto

El trabajo comprendió el desarrollo de un prototipo funcional orientado a demostrar la factibilidad técnica y el valor práctico del enfoque. El alcance incluyó:

- La carga y validación de archivos históricos exportados desde el CRM.
- La limpieza, tipificación y consolidación de los snapshots, junto con la construcción de una tabla mensual de modelado.
- La definición de las contrataciones a partir de oportunidades ganadas, deduplicadas y agregadas por fecha de cierre.

- La generación de rezagos, estadísticas móviles y variables agregadas del estado del pipeline.
- El entrenamiento, la validación temporal, la comparación y el ajuste de distintas familias de modelos.
- El registro reproducible de experimentos y la exportación de proyecciones y métricas para su análisis.
- La documentación de decisiones, limitaciones, resultados y hallazgos negativos relevantes.

Quedaron fuera del alcance la conexión en tiempo real con el CRM, el desarrollo de una interfaz de usuario, el despliegue productivo y el modelado financiero posterior a la proyección. Tampoco se realizó una segmentación geográfica, debido a que la fuente disponible no contenía una dimensión de región. El trabajo se efectuó dentro de la infraestructura autorizada por la organización. Para la documentación académica se utilizaron descripciones, métricas y resultados agregados, sin publicar nombres de clientes, contactos ni datos crudos que permitieran identificar personas u oportunidades comerciales.

1.7. Organización de la memoria

El resto de la memoria se organiza de la siguiente manera. En el capítulo 2 se presenta la introducción específica, que describe el conjunto de datos, las bibliotecas, los modelos y la infraestructura de cómputo utilizados. En el capítulo 3 se detalla el diseño y la implementación del pipeline, la construcción point in time del conjunto supervisado, la arquitectura de modelado y el proceso de entrenamiento. En el capítulo 4 se expone el plan de evaluación y se analizan los resultados, los errores y las limitaciones de los modelos. Finalmente, en el capítulo 5 se presentan los logros alcanzados, los conocimientos aplicados, las conclusiones y las posibles líneas de trabajo futuro.

Capítulo 2

Introducción específica

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

2.1. Estilo y convenciones

2.1.1. Uso de mayúscula inicial para los título de secciones

Si en el texto se hace alusión a diferentes partes del trabajo referirse a ellas como capítulo, sección o subsección según corresponda. Por ejemplo: “En el capítulo 1 se explica tal cosa”, o “En la sección 2.1 se presenta lo que sea”, o “En la subsección 2.1.2 se discute otra cosa”.

Cuando se quiere poner una lista tabulada, se hace así:

- Este es el primer elemento de la lista.
- Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

Si se desea poner una lista numerada el formato es este:

1. Este es el primer elemento de la lista.
2. Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

2.1.2. Este es el título de una subsección

Se recomienda no utilizar **texto en negritas** en ningún párrafo, ni tampoco texto subrayado. En cambio sí se debe utilizar *texto en itálicas* para palabras en un idioma extranjero, al menos la primera vez que aparecen en el texto. En el caso de palabras que estamos inventando se deben utilizar “comillas”, así como también para citas textuales. Por ejemplo, un *digital filter* es una especie de “selector” que permite separar ciertos componentes armónicos en particular.

La escritura debe ser impersonal. Por ejemplo, no utilizar “el diseño del firmware lo hice de acuerdo con tal principio”, sino “el firmware fue diseñado utilizando tal principio”.

El trabajo es algo que al momento de escribir la memoria se supone que ya está concluido, entonces todo lo que se refiera a hacer el trabajo se narra en tiempo pasado, porque es algo que ya ocurrió. Por ejemplo, "se diseñó el firmware empleando la técnica de test driven development".

En cambio, la memoria es algo que está vivo cada vez que el lector la lee. Por eso transcurre siempre en tiempo presente, como por ejemplo:

"En el presente capítulo se da una visión global sobre las distintas pruebas realizadas y los resultados obtenidos. Se explica el modo en que fueron llevados a cabo los test unitarios y las pruebas del sistema".

Se recomienda no utilizar una sección de glosario sino colocar la descripción de las abreviaturas como parte del mismo cuerpo del texto. Por ejemplo, RTOS (*Real Time Operating System*, Sistema Operativo de Tiempo Real) o en caso de considerarlo apropiado mediante notas a pie de página.

Si se desea indicar alguna página web puede incorporarse su dirección directamente en el texto. Por ejemplo, "el presente trabajo se basa en la plataforma EDU-CIAA-NXP, la cual...".

2.1.3. Figuras

Al insertar figuras en la memoria se deben considerar determinadas pautas. Para empezar, usar siempre tipografía claramente legible. Luego, tener claro que **es incorrecto** escribir por ejemplo esto: "El diseño elegido es un cuadrado, como se ve en la siguiente figura:"



La forma correcta de utilizar una figura es con referencias cruzadas, por ejemplo: "Se eligió utilizar un cuadrado azul para el logo, como puede observarse en la figura 2.1".



FIGURA 2.1. Ilustración del cuadrado azul que se eligió para el diseño del logo.

El texto de las figuras debe estar siempre en español, excepto que se decida reproducir una figura original tomada de alguna referencia. En ese caso la referencia de la cual se tomó la figura debe ser indicada en el epígrafe de la figura e incluida como una nota al pie, como se ilustra en la figura 2.2.

¹Imagen tomada de <https://goo.gl/images/i7C70w>

FIGURA 2.2. Imagen tomada de la página oficial del procesador¹.

La figura y el epígrafe deben conformar una unidad cuyo significado principal pueda ser comprendido por el lector sin necesidad de leer el cuerpo central de la memoria. Para eso es necesario que el epígrafe sea todo lo detallado que corresponda y si en la figura se utilizan abreviaturas entonces aclarar su significado en el epígrafe o en la misma figura.



FIGURA 2.3. ¿Por qué de pronto aparece esta figura?

Nunca colocar una figura en el documento antes de hacer la primera referencia a ella, como se ilustra con la figura 2.3, porque sino el lector no comprenderá por qué de pronto aparece la figura en el documento, lo que distraerá su atención.

Otra posibilidad es utilizar el entorno *subfigure* para incluir más de una figura, como se puede ver en la figura 2.4. Notar que se pueden referenciar también las figuras internas individualmente de esta manera: 2.4a, 2.4b y 2.4c.



(A) Un caption.



(B) Otro.



(C) Y otro más.

FIGURA 2.4. Tres gráficos simples.

El código para generar las imágenes se encuentra disponible para su reutilización en el archivo Chapter2.tex.

2.1.4. Tablas

Para las tablas utilizar el mismo formato que para las figuras, sólo que el epígrafe se debe colocar arriba de la tabla, como se ilustra en la tabla 2.1. Observar que sólo algunas filas van con líneas visibles y notar el uso de las negritas para los encabezados. La referencia se logra utilizando el comando `\ref{<label>}` donde label debe estar definida dentro del entorno de la tabla.

```
\begin{table}[h]
\centering
```

```

\caption[caption corto]{caption largo más descriptivo}
\begin{tabular}{l c c}
\toprule
\textbf{Especie} & \textbf{Tamaño} & \textbf{Valor}\\
\midrule
Amphiprion Ocellaris & 10 cm & \$ 6.000 \\
Hepatus Blue Tang & 15 cm & \$ 7.000 \\
Zebrasoma Xanthurus & 12 cm & \$ 6.800 \\
\bottomrule
\hline
\end{tabular}
\label{tab:peces}
\end{table}

```

TABLA 2.1. caption largo más descriptivo.

Especie	Tamaño	Valor
Amphiprion Ocellaris	10 cm	\$ 6.000
Hepatus Blue Tang	15 cm	\$ 7.000
Zebrasoma Xanthurus	12 cm	\$ 6.800

En cada capítulo se debe reiniciar el número de conteo de las figuras y las tablas, por ejemplo, figura 2.1 o tabla 2.1, pero no se debe reiniciar el conteo en cada sección. Por suerte la plantilla se encarga de esto por nosotros.

2.1.5. Ecuaciones

Al insertar ecuaciones en la memoria dentro de un entorno *equation*, éstas se numeran en forma automática y se pueden referir al igual que como se hace con las figuras y tablas, por ejemplo ver la ecuación 2.1.

$$ds^2 = c^2 dt^2 \left(\frac{d\sigma^2}{1 - k\sigma^2} + \sigma^2 [d\theta^2 + \sin^2 \theta d\phi^2] \right) \quad (2.1)$$

Para generar la ecuación 2.1 se utilizó el siguiente código:

```

\begin{equation}
\label{eq:metric}
ds^2 = c^2 dt^2 \left( \frac{d\sigma^2}{1-k\sigma^2} + \right.
\sigma^2 \left[ d\theta^2 + \sin^2 \theta d\phi^2 \right] \left. \right)
\end{equation}

```

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

Se puede agregar código o pseudocódigo dentro de un entorno `lstlisting` con el siguiente código:

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
las líneas de código irían aquí...
\end{lstlisting}
```

A modo de ejemplo, se muestra el fragmento de código [3.1](#):

```
1 #define MAX_SENSOR_NUMBER 3
2 #define MAX_ALARM_NUMBER 6
3 #define MAX_ACTUATOR_NUMBER 6
4
5 uint32_t sensorValue[MAX_SENSOR_NUMBER];
6 FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
7 state_t alarmState[MAX_ALARM_NUMBER]; //ON or OFF
8 state_t actuatorState[MAX_ACTUATOR_NUMBER]; //ON or OFF
9
10 void vControl() {
11
12     initGlobalVariables();
13
14     period = 500 ms;
15
16     while(1) {
17
18         ticks = xTaskGetTickCount();
19
20         updateSensors();
21
22         updateAlarms();
23
24         controlActuators();
25
26         vTaskDelayUntil(&ticks, period);
27     }
```

28 }

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.